


LeNet-5 (1998)

1. Cổ máy đọc chữ

Vào những năm 90, việc phân loại chữ viết tay là một bài toán cực khó. LeNet-5 được thiết kế để giải quyết một nhiệm vụ cụ thể: Nhận diện các chữ số viết tay trên các tấm séc ngân hàng (bộ dữ liệu MNIST). Thay vì bắt máy tính nhìn vào từng điểm ảnh (pixel) một cách rời rạc, LeNet-5 dạy nó cách nhìn theo từng cụm để nhận ra các đường nét, góc cạnh.

2. Kiến trúc của LeNet-5 (Gồm 7 lớp chính)

- Hãy tưởng tượng hình ảnh đi qua một "dây chuyền lọc" để trích xuất thông tin:
- Lớp Input: Là một hình ảnh đen trắng kích thước 32x32 pixel chứa một chữ số.
 - Các lớp Tích chập (Convolution - C1, C3, C5): Đây là những bộ lọc (filter). Chúng quét qua hình ảnh để tìm các đặc điểm như đường thẳng, đường cong, hay vòng tròn.
 - Các lớp Lấy mẫu (Pooling/Subsampling - S2, S4): Sau khi tìm được các nét, mạng sẽ làm gọn dữ liệu lại bằng cách giảm độ phân giải, chỉ giữ lại những thông tin quan trọng nhất. Việc này giúp mạng không bị "rối" bởi các chi tiết thừa.
 - Lớp Kết nối đầy đủ (Fully Connected - F6 & Output): Sau khi đã hiểu được hình dạng (ví dụ: có hai vòng tròn chồng lên nhau), mạng sẽ tổng hợp lại và đưa ra kết luận cuối cùng: "Đây là số 8 với độ tự tin 98%".
 - Số lượng tham số: ~60.000



Khi hình ảnh đi qua lớp tích chập, thực chất là một phép tính nhân ma trận giữa Filter (bộ lọc) và vùng ảnh đó:

$$Output = \sigma(\sum (Input \times Kernel) + bias)$$

Trong đó σ thường là hàm kích hoạt (như Sigmoid hoặc Tanh trong nguyên bản LeNet-5) để giúp mạng học được các quy luật phức tạp.

3. Tại sao LeNet-5 lại quan trọng?

Dù ngày nay chúng ta có những mô hình mạnh hơn gấp hàng nghìn lần, LeNet-5 vẫn là "sách giáo khoa" vì nó giới thiệu 3 ý tưởng cốt lõi:

- Local Receptive Fields: Chỉ nhìn vào từng vùng nhỏ của ảnh thay vì nhìn toàn bộ cùng lúc.
- Shared Weights: Dùng chung một bộ lọc cho toàn bộ ảnh để giảm lượng tính toán.
- Spatial Subsampling: Giảm kích thước ảnh để mô hình bền vững hơn với các thay đổi nhỏ (như chữ viết hơi nghiêng hay lệch).

4. Vấn đề

1. Biến mất Gradient" (Vanishing Gradient)

Việc sử dụng Sigmoid hoặc Tanh là một rào cản lớn vì khi giá trị đầu vào quá lớn hoặc quá nhỏ, đạo hàm của các hàm này tiến dần về 0. Trong quá trình Backpropagation, các giá trị đạo hàm nhỏ này nhân liên tiếp với nhau qua các lớp, khiến tín hiệu sai số bị "triệt tiêu" trước khi kịp cập nhật các lớp đầu tiên. Giải pháp sau này: Thay thế bằng ReLU $f(x) = \max(0, x)$ để giữ đạo hàm bằng 1 cho mọi giá trị dương.

2. Khả năng tính toán (Computational Power)

Vào năm 1998, phần cứng (CPU) rất yếu và chưa có khái niệm dùng GPU để huấn luyện, LeNet-5 chỉ có khoảng 60.000 tham số (parameters). Nếu làm mạng sâu hơn vào lúc đó, máy tính đơn giản là không thể chạy nổi.

3. Thiếu các kỹ thuật "Chống học vẹt" (Regularization)

LeNet-5 chưa áp dụng các kỹ thuật mạnh mẽ để ngăn chặn việc mô hình quá khớp (Overfitting) với dữ liệu huấn luyện:

Dropout: Không có cơ chế ngắt ngẫu nhiên các nơ-ron để ép mạng học các đặc trưng tổng quát hơn.

Batch Normalization: Chưa có lớp chuẩn hóa dữ liệu giữa các tầng, khiến việc huấn luyện rất nhạy cảm với cách khởi tạo trọng số ban đầu.

4. Thuật toán lấy mẫu (Subsampling)

Trong bài báo LeNet-5, tác giả dùng Average Pooling (lấy giá trị trung bình). Cách này vô tình làm "mờ" đi các đặc trưng sắc nét của ảnh. Các mạng sau này (như AlexNet) đã chuyển sang Max Pooling (lấy giá trị lớn nhất), giúp giữ lại những tín hiệu mạnh nhất (như cạnh sắc, góc nhọn) hiệu quả hơn nhiều.