

AlexNet (2012)

1. Tại sao AlexNet lại gây chấn động?


Trước năm 2012, các nhà khoa học thường dùng các thuật toán thủ công để trích xuất đặc trưng ảnh. AlexNet đã chứng minh rằng: Cứ để mạng thần kinh thật sâu tự học trực tiếp từ dữ liệu thô, nó sẽ làm tốt hơn con người gấp nhiều lần.

2. Những "vũ khí" mới của AlexNet (Giải quyết các yếu điểm của LeNet-5)

- AlexNet kế thừa cấu trúc của LeNet-5 nhưng được nâng cấp cực kỳ mạnh mẽ để xử lý các hình ảnh thực tế (màu sắc, kích thước lớn, vật thể đa dạng):
- Dùng ReLU thay cho Sigmoid: Như bạn đã dự đoán trước đó, AlexNet sử dụng hàm kích hoạt ReLU ($f(x) = \max(0, x)$). Điều này giúp mạng học nhanh hơn gấp 6 lần và triệt tiêu vấn đề biến mất gradient.
 - Sức mạnh của GPU: Lần đầu tiên, một mạng thần kinh lớn được huấn luyện song song trên 2 card đồ họa (NVIDIA GTX 580). Nếu không có GPU, việc huấn luyện AlexNet trên 1,2 triệu tấm ảnh sẽ mất hàng năm trời thay vì vài ngày.
 - Kỹ thuật Dropout: Để chống lại việc "học vẹt" (overfitting), AlexNet ngẫu nhiên "tắt" 50% các nơ-ron trong quá trình huấn luyện. Điều này ép mạng phải học những đặc trưng tổng quát và bền vững hơn.
 - Data Augmentation (Tăng cường dữ liệu): Họ lật ảnh, cắt ảnh, thay đổi cường độ sáng để tạo ra hàng triệu biến thể khác nhau, giúp mạng nhận diện được vật thể dù nó nằm ở góc độ nào.
 - Max Pooling: Thay vì lấy trung bình (như LeNet-5), AlexNet dùng Max Pooling để giữ lại những tín hiệu mạnh nhất, sắc nét nhất của hình ảnh.

3. Kiến trúc gồm 8 lớp (5 Convolution + 3 Fully Connected)

- Lớp 1 (Conv1): Nhận ảnh màu RGB kích thước 224x224x3. Sử dụng 96 bộ lọc (11x11), bước nhảy (stride) là 4. Nhiệm vụ là tìm các đặc trưng thô như cạnh, góc, màu sắc cơ bản.
- Lớp 2 (Conv2): Sử dụng 256 bộ lọc (5x5). Ở đây bắt đầu áp dụng Padding (đệm thêm viền 0) để giữ kích thước ảnh không bị thu hẹp quá nhanh.
- Lớp 3 & 4 (Conv3, Conv4): Hai lớp này được xếp chồng trực tiếp lên nhau mà không có lớp Pooling ở giữa. Chúng sử dụng 384 bộ lọc (3x3). Mục đích: Giúp mạng học được các cấu trúc hình học phức tạp hơn (như hình dáng cái tai, cái bánh xe).
- Lớp 5 (Conv5): Lớp tích chập cuối cùng với 256 bộ lọc (3x3). Sau lớp này là một lớp Max Pooling để nén dữ liệu lại trước khi đưa vào các lớp phân loại.
- Các lớp Kết nối đầy đủ (Fully Connected Layers - ra quyết định): Sau khi qua 5 lớp tích chập, dữ liệu được "duỗi phẳng" (Flatten) thành một vector dài để đưa vào các lớp Dense:
 - + Lớp 6 & 7 (FC6, FC7): Mỗi lớp có 4096 nơ-ron. Đây là nơi tiêu tốn nhiều bộ nhớ nhất (chiếm phần lớn trong số 60 triệu tham số của mạng). Tại đây, kỹ thuật Dropout (0.5) được áp dụng: Ngẫu nhiên "tắt" một nửa số nơ-ron trong mỗi lần học để tránh mạng bị phụ thuộc quá mức vào một vài kết nối nhất định.
 - + Lớp 8 (Output Layer - FC8): Sử dụng hàm Softmax với 1000 nơ-ron, tương ứng với 1000 nhãn vật thể của bộ dữ liệu ImageNet (như con chó, con mèo, cái tàu hỏa...)



AlexNet Architecture (~60M Parameters)

Công thức tính kích thước Output:
Để hiểu tại sao AlexNet lại sâu và rộng như vậy, hãy nhìn vào cách một lớp tích chập thay đổi kích thước ảnh. Với ảnh đầu vào W, bộ lọc F, bước nhảy S và phần đệm P, kích thước đầu ra W_{out} được tính bằng:

$$W_{out} = \frac{W - F + 2P}{S} + 1$$

Kết quả là một khối dữ liệu 55x55 với độ sâu 96 lớp (96 bộ lọc).

4. Những thành phần hỗ trợ "làm nên tên tuổi"

- Ngoài các lớp chính, AlexNet còn tích hợp:
- Hàm kích hoạt ReLU: Áp dụng sau mỗi lớp Conv và FC. Nó giúp tốc độ hội tụ nhanh hơn hẳn so với hàm Sigmoid hay Tanh.
 - Overlapping Pooling: Thay vì dùng các vùng pooling không chạm nhau, AlexNet dùng vùng 3x3 với bước nhảy là 2 (chúng đè lên nhau). Tác giả cho rằng điều này giúp giảm lỗi Overfitting.
 - LRN (Local Response Normalization): Một dạng chuẩn hóa lấy cảm hứng từ sinh học (ức chế các nơ-ron lân cận). Tuy nhiên, các kiến trúc sau này (như VGG hay ResNet) thường bỏ qua LRN vì nó không đem lại hiệu quả quá lớn so với các kỹ thuật mới như Batch Norm.

5. Vấn đề

1. Quá nhiều tham số (60 triệu parameters)
Đây là vấn đề đau đầu nhất. Hầu hết các tham số này nằm ở 3 lớp Fully Connected (FC) cuối cùng. Việc có quá nhiều tham số khiến mô hình cực kỳ nặng (file lưu trữ lớn). Nó đòi hỏi bộ nhớ GPU rất cao, dẫn đến việc tác giả phải chia đôi mạng chạy trên 2 GPU—một kỹ thuật rất phức tạp để lập trình vào thời điểm đó.
2. Nguy cơ Overfitting (Học vẹt) cực cao
Với 60 triệu tham số nhưng lượng dữ liệu (dù là 1.2 triệu ảnh) vẫn có thể là "chưa đủ" để mạng học một cách tổng quát. Nếu không có Dropout và Data Augmentation (tăng cường dữ liệu), AlexNet sẽ dễ dàng học thuộc lòng các bức ảnh thay vì học các đặc trưng của vật thể. Điều này khiến việc huấn luyện AlexNet trở nên rất "nhạy cảm", cần phải tinh chỉnh kỹ lưỡng các siêu tham số (hyperparameters).
3. Kích thước Filter quá lớn (11x11)
Lớp đầu tiên của AlexNet dùng Filter 11x11. Bộ lọc lớn làm mất đi nhiều chi tiết nhỏ, tinh tế của hình ảnh và cực kỳ tốn kém về mặt tính toán. Sự cải tiến sau này: Các mạng như VGGNet đã chứng minh rằng thay vì dùng một bộ lọc 11x11, ta có thể dùng nhiều bộ lọc 3x3 chồng lên nhau. Cách này vừa giúp mạng sâu hơn, vừa ít tham số hơn mà vẫn đạt được cùng một "tầm nhìn" (receptive field).
4. LRN (Local Response Normalization) không thực sự hiệu quả
AlexNet sử dụng lớp LRN để mô phỏng sự ức chế của các nơ-ron trong não người. Tuy nhiên, các nghiên cứu sau này chỉ ra rằng LRN không giúp ích nhiều cho độ chính xác của mạng. Nó làm tăng khối lượng tính toán nhưng hiệu quả mang lại rất thấp. Sau này, kỹ thuật Batch Normalization ra đời đã hoàn toàn thay thế và làm tốt hơn LRN rất nhiều.
5. Vẫn chưa đủ "Sâu"
Dù 8 lớp là một bước tiến so với 5 lớp của LeNet-5, nhưng AlexNet vẫn bị giới hạn bởi khả năng hội tụ. Nếu chỉ đơn giản là xếp thêm các lớp giống AlexNet lên nhau, mạng sẽ gặp vấn đề Exploding/Vanishing Gradient (bùng nổ hoặc biến mất đạo hàm) khiến việc huấn luyện thất bại.